In [1]:

```
# ładowanie biblioteki Pandas
import pandas as pd

# zaimportuj moduł pyplot z biblioteki matplotlib
import matplotlib.pyplot as plt

# wskazać, że wykresy należy rysować bezpośrednio w zeszycie, a nie w osobnej zakładce
%matplotlib inline

# tworzenie ramki danych ze słownika
slownik = {"Kraj": ["Polska", "Niemcy", "Czechy"], "Powszechnosc_Palenia": [0.25, 0.22, 0.28]}
df_slownik = pd.DataFrame(slownik)

# tworzenie ramki danych z listy list
lista_list = [["Polska", 0.25], ["Niemcy", 0.22], ["Czechy", 0.28]]
df_lista = pd.DataFrame(lista_list, columns=["Kraj", "Powszechnosc_Palenia"])

# transponowanie (wymieniamy kolumny a wierszy)
df_transponowane = df_lista.T

# zachowanie ramki danych pobranych z pliku w formacie csv (xlsx)
plik_prev = 'IHME_GBD_2019_SMOKING_AGE_1990_2019_PREV_Y2021M05D27.CSV'
df = pd.read_csv(plik_prev)

# wyświetlić pierwsze 10 wierszy ramki danych
display(df.head(10))

# wyświetlić ostatnie 10 wierszy ramki danych
display(df.tail(10))

# wyświetlić informację o ramce danych
df.info()

# wyświetlić, ile wierszy i kolumn znajduje się w ramce danych
print("Wymiary:", df.shape)

# wyświetlić informację statystyczną o kolumnach liczbowych
display(df.describe())
```

```python
# wyświetlić informację statystyczną o kolumnach kategoryzowanych
display(df.describe(include=['object']))

# usunąć brakujące wartości w ramce danych
df.dropna(inplace=True)

# przedstawić wybór wierszy i kolumny używając nazw oraz indeksów na różne sposoby
# a) Wybór kolumn po nazwach
wybor_nazwy = df[['location_name', 'sex_name', 'val']]
# b) Wybór wierszy i kolumn przez lokator oparty na etykietach (loc)
wybor_loc = df.loc[10:20, 'location_name':'val']
# c) Wybór wierszy i kolumn przez lokator oparty na indeksach (iloc)
wybor_iloc = df.iloc[10:20, 0:5]

# przedstawić wybór wierszy z ramki danych pod warunkiem odnośnie określonej wartości kolumny
df_mezczyzni = df[df['sex_name'] == 'Male']

# przedstawić wybór wierszy z ramki danych pod warunkiem spełnienia kilku warunków jednocześnie
df_warunki = df[(df['sex_name'] == 'Female') & (df['year_id'].astype(str) == '2019')]

# wybrać wiersze które zawierają w kolumnie kategoryzowanej określone słowo
df_polska = df[df['location_name'].str.contains('Poland', na=False)]

# wybrać wiersze które nie zawierają w kolumnie kategoryzowanej określone słowo
df_nie_polska = df[~df['location_name'].str.contains('Poland', na=False)]

# utwórz kolumnę na podstawie istniejących
df['rozstep_wartosci'] = df['upper'] - df['lower']

# usuń kolumnę
df.drop('rozstep_wartosci', axis=1, inplace=True)

# zmień nazwę kolumny
df.rename(columns={'val': 'wartosc_wskaznika'}, inplace=True)

# zachowaj ramkę danych jako plik csv na komputerze
df.to_csv('moje_wyniki_GBD.csv', index=False)

# wyświetlić średnia (maksymalną, minimalną) wartość z jednej kolumny
print("Średnia:", df['wartosc_wskaznika'].mean())
print("Maksimum:", df['wartosc_wskaznika'].max())
```

```python
print("Minimum:", df['wartosc_wskaznika'].min())

# wyświetlić liczbę wierszy
print("Liczba wierszy:", len(df))

# wyświetlić wartości unikatowe w kolumnie
print("Unikatowe kraje:", df['location_name'].unique())

# wyświetlić liczby rekordów odpowiadających do wartości
display(df['location_name'].value_counts())

# sortowanie wierszy ramki danych według wartości określonej kolumny (malejąco, rosnąco)
df_malejaco = df.sort_values(by='wartosc_wskaznika', ascending=False)
df_rosnaco = df.sort_values(by='wartosc_wskaznika', ascending=True)

# wyświetlić wierszy dla 10 największych (najmniejszych) wartości określonej kolumny
display(df.nlargest(10, 'wartosc_wskaznika'))
display(df.nsmallest(10, 'wartosc_wskaznika'))

# wyświetlić wierszy dla 10 największych wartości określonej kolumny pod warunkiem określonych wartości innej kolumny
display(df[df['sex_name'] == 'Female'].nlargest(10, 'wartosc_wskaznika'))

# grupowanie wierszy wedlug wartości kolumny kategoryzowanej, potem uśrednienie wartości wszystkich kolumn w grupie MultiIndex
df_zgrupowane = df.groupby(['location_name', 'sex_name']).mean(numeric_only=True)
display(df_zgrupowane)

# grupowanie wierszy wedlug wartości kolumny kategoryzowanej, potem - uśrednienie wartości dla pewnych kolumn, liczba wartości
df_agg = df.groupby('location_name').agg({
    'wartosc_wskaznika': 'mean',
    'upper': 'median',
    'lower': 'count'
})
display(df_agg)

# wyświetlić nazwy kolumn indeksu złożonego
print(df_zgrupowane.index.names)

# sortować kolumnę indeksu złożonego
display(df_zgrupowane.sort_index())

# stworzyć tabelę przystawną (pivot table) na podstawie ramki danych
```

```
tabela_przestawna = df.pivot_table(values='wartosc_wskaznika', index='location_name', columns='sex_name', aggfunc='mean')
display(tabela_przestawna)

# wyświetlić indeksy i kolumny tabeli przystawnej
print("Indeksy tabeli:", tabela_przestawna.index)
print("Kolumny tabeli:", tabela_przestawna.columns)

# utwórz indeks złożony tabeli przystawnej i wyświetl go
tabela_zlozona = df.pivot_table(values='wartosc_wskaznika', index=['location_name', 'age_group_name'], columns='sex_name', agg
display(tabela_zlozona)

# wyświetlić wykres na podstawie tabeli przystawnej (wybieramy 10 pierwszych, aby uniknąć nakładających się etykiet)
tabela_przestawna.head(10).plot(kind='bar', figsize=(12, 6))
plt.title('Średni wskaźnik powszechności palenia wg płci (próbka)')
plt.ylabel('Powszechność palenia')
plt.xlabel('Kraj')
plt.xticks(rotation=45, ha='right')
plt.show()

# narysować histogram na podstawie wartości kolumny
df['wartosc_wskaznika'].plot(kind='hist', bins=30, figsize=(10, 6), color='skyblue', edgecolor='black')
plt.title('Rozkład wskaźnika powszechności palenia')
plt.xlabel('Wartość wskaźnika')
plt.ylabel('Częstotliwość')
plt.show()

# przedstawić sposoby łączenia ramek danych za pomocą metod merge i concat
# CONCAT
df_czesc1 = df.iloc[:50, :]
df_czesc2 = df.iloc[50:100, :]
df_polaczone_concat = pd.concat([df_czesc1, df_czesc2], axis=0)

# MERGE
plik_init = 'IHME_GBD_2019_SMOKING_AGE_1990_2019_INIT_AGE_Y2021M05D27.CSV'
df_init = pd.read_csv(plik_init)
df_init.rename(columns={'val': 'wiek_inicjacji'}, inplace=True)

# KONIECZNE DLA MERGE: Ujednolicenie typów dla 'year_id' w obu ramkach
df['year_id'] = df['year_id'].astype(str)
df_init['year_id'] = df_init['year_id'].astype(str)
```

```python
# łączymy po najbezpieczniejszych wspólnych kluczach
df_polaczone_merge = pd.merge(df, df_init, on=['location_name', 'sex_name', 'year_id'], how='inner')

# pokazać dodawanie nowych kolumn za pomocą operacji matematycznych
srednia_w_zbiorze = df_polaczone_merge['wiek_inicjacji'].mean()
df_polaczone_merge['odchylenie_od_sredniej_inicjacji'] = df_polaczone_merge['wiek_inicjacji'] - srednia_w_zbiorze

# przedstawić na przykładzie dodawanie nowych kolumn z pomocą funkcji lambda
df['czy_mezczyzni'] = df['sex_name'].apply(lambda x: True if x == 'Male' else False)

# przedstawić możliwości pracy z dużymi plikami przy użyciu argumentu chunksize
print("\nPrzykład pracy z argumentem chunksize:")
for fragment_df in pd.read_csv(plik_prev, chunksize=500):
    print("Rozmiar przetworzonego fragmentu (chunk):", fragment_df.shape)
```

	measure_name	location_id	location_name	sex_id	sex_name	age_group_id	age_group_name	year_id	val	upper	lower
0	Prevalence	1	Global	1	Male	149	15 to 24	2019	0.201031	0.208351	0.194303
1	Prevalence	1	Global	2	Female	149	15 to 24	2019	0.049511	0.052887	0.046406
2	Prevalence	4	Southeast Asia, East Asia, and Oceania	1	Male	149	15 to 24	2019	0.320305	0.339934	0.301512
3	Prevalence	4	Southeast Asia, East Asia, and Oceania	2	Female	149	15 to 24	2019	0.026897	0.034973	0.021596
4	Prevalence	6	China	1	Male	149	15 to 24	2019	0.301431	0.332005	0.269564
5	Prevalence	6	China	2	Female	149	15 to 24	2019	0.021667	0.035488	0.013407
6	Prevalence	7	Democratic People's Republic of Korea	1	Male	149	15 to 24	2019	0.259976	0.308964	0.213969
7	Prevalence	7	Democratic People's Republic of Korea	2	Female	149	15 to 24	2019	0.024088	0.042122	0.011970
8	Prevalence	8	Taiwan (Province of China)	1	Male	149	15 to 24	2019	0.245859	0.288292	0.203466
9	Prevalence	8	Taiwan (Province of China)	2	Female	149	15 to 24	2019	0.045195	0.079341	0.023168

	measure_name	location_id	location_name	sex_id	sex_name	age_group_id	age_group_name	year_id	val	upper	lower
1262	Percent Change in Prevalence	413	Tokelau	1	Male	149	15 to 24	1990-2019	-0.030866	0.249448	-0.268365
1263	Percent Change in Prevalence	413	Tokelau	2	Female	149	15 to 24	1990-2019	0.036577	0.862182	-0.507623
1264	Percent Change in Prevalence	416	Tuvalu	1	Male	149	15 to 24	1990-2019	0.161877	0.479724	-0.078990
1265	Percent Change in Prevalence	416	Tuvalu	2	Female	149	15 to 24	1990-2019	0.412200	1.868836	-0.314228
1266	Percent Change in Prevalence	422	United States Virgin Islands	1	Male	149	15 to 24	1990-2019	-0.178776	0.243252	-0.459573
1267	Percent Change in Prevalence	422	United States Virgin Islands	2	Female	149	15 to 24	1990-2019	0.021706	1.422649	-0.645631
1268	Percent Change in Prevalence	435	South Sudan	1	Male	149	15 to 24	1990-2019	-0.205300	0.125496	-0.462817
1269	Percent Change in Prevalence	435	South Sudan	2	Female	149	15 to 24	1990-2019	-0.016307	1.234899	-0.606017
1270	Percent Change in Prevalence	522	Sudan	1	Male	149	15 to 24	1990-2019	-0.126616	0.205080	-0.374482
1271	Percent Change in Prevalence	522	Sudan	2	Female	149	15 to 24	1990-2019	0.103440	1.407856	-0.562403

```
<class 'pandas.DataFrame'>
RangeIndex: 1272 entries, 0 to 1271
Data columns (total 11 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   measure_name    1272 non-null   str
 1   location_id     1272 non-null   int64
 2   location_name   1272 non-null   str
 3   sex_id          1272 non-null   int64
 4   sex_name        1272 non-null   str
 5   age_group_id    1272 non-null   int64
 6   age_group_name  1272 non-null   str
 7   year_id         1272 non-null   str
 8   val             1272 non-null   float64
 9   upper           1272 non-null   float64
 10  lower           1272 non-null   float64
dtypes: float64(3), int64(3), str(5)
memory usage: 109.4 KB
Wymiary: (1272, 11)
```

	location_id	sex_id	age_group_id	val	upper	lower
count	1272.000000	1272.000000	1272.0	1.272000e+03	1.272000e+03	1.272000e+03
mean	134.287736	1.500000	149.0	3.645334e+05	4.033136e+05	3.301779e+05
std	97.404833	0.500197	0.0	4.069578e+06	4.268955e+06	3.887326e+06
min	1.000000	1.000000	149.0	-7.588282e-01	-6.736115e-01	-8.420966e-01
25%	61.750000	1.000000	149.0	2.111960e-02	1.288786e-01	-2.788391e-01
50%	121.500000	1.500000	149.0	2.258776e-01	4.263123e-01	1.246196e-01
75%	180.250000	2.000000	149.0	1.181078e+04	1.657995e+04	8.223125e+03
max	522.000000	2.000000	149.0	1.249957e+08	1.295466e+08	1.208124e+08

```
C:\Users\Kacper\AppData\Local\Temp\ipykernel_2508\3231290958.py:53: Pandas4Warning: For backward compatibility, 'str' dtypes ar
e included by select_dtypes when 'object' dtype is specified. This behavior is deprecated and will be removed in a future versi
on. Explicitly pass 'str' to `include` to select them, or to `exclude` to remove them and silence this warning.
See https://pandas.pydata.org/docs/user_guide/migration-3-strings.html#string-migration-select-dtypes for details on how to wri
te code that works with pandas 2 and 3.
  display(df.describe(include=['object']))
```

	measure_name	location_name	sex_name	age_group_name	year_id
count	1272	1272	1272	1272	1272
unique	3	212	2	1	2
top	Prevalence	Global	Male	15 to 24	2019
freq	424	6	636	1272	848

```
Średnia: 364533.3700294625
Maksimum: 124995683.5
Minimum: -0.758828209
Liczba wierszy: 1272
Unikatowe kraje: <StringArray>
[                               'Global',
 'Southeast Asia, East Asia, and Oceania',
                                'China',
  'Democratic People's Republic of Korea',
            'Taiwan (Province of China)',
                              'Cambodia',
                             'Indonesia',
       'Lao People's Democratic Republic',
                              'Malaysia',
                              'Maldives',
 ...
               'Northern Mariana Islands',
                                'Palau',
                            'Puerto Rico',
                  'Saint Kitts and Nevis',
                              'San Marino',
                                 'Tokelau',
                                 'Tuvalu',
           'United States Virgin Islands',
                            'South Sudan',
                                 'Sudan']
Length: 212, dtype: str
location_name
Global                                    6
Southeast Asia, East Asia, and Oceania    6
China                                     6
Democratic People's Republic of Korea     6
Taiwan (Province of China)                6
                                         ..
Tokelau                                   6
Tuvalu                                    6
United States Virgin Islands              6
South Sudan                               6
Sudan                                     6
Name: count, Length: 212, dtype: int64
```

	measure_name	location_id	location_name	sex_id	sex_name	age_group_id	age_group_name	year_id	wartosc_wskaznika	upp
424	Number of Smokers	1	Global	1	Male	149	15 to 24	2019	1.249957e+08	1.295466e+0
426	Number of Smokers	4	Southeast Asia, East Asia, and Oceania	1	Male	149	15 to 24	2019	4.625058e+07	4.908483e+0
425	Number of Smokers	1	Global	2	Female	149	15 to 24	2019	2.956645e+07	3.158243e+0
428	Number of Smokers	6	China	1	Male	149	15 to 24	2019	2.497735e+07	2.751081e+0
702	Number of Smokers	158	South Asia	1	Male	149	15 to 24	2019	2.446499e+07	2.768826e+0
710	Number of Smokers	163	India	1	Male	149	15 to 24	2019	1.731707e+07	2.042377e+0
534	Number of Smokers	64	High-income	1	Male	149	15 to 24	2019	1.588241e+07	1.652767e+0
662	Number of Smokers	137	North Africa and Middle East	1	Male	149	15 to 24	2019	1.344276e+07	1.397654e+0
535	Number of Smokers	64	High-income	2	Female	149	15 to 24	2019	1.073082e+07	1.151689e+0
716	Number of Smokers	166	Sub-Saharan Africa	1	Male	149	15 to 24	2019	1.032247e+07	1.081519e+0

	measure_name	location_id	location_name	sex_id	sex_name	age_group_id	age_group_name	year_id	wartosc_wskaznika	upper
1083	Percent Change in Prevalence	135	Brazil	2	Female	149	15 to 24	1990-2019	-0.758828	-0.654538
1082	Percent Change in Prevalence	135	Brazil	1	Male	149	15 to 24	1990-2019	-0.736061	-0.673611
1005	Percent Change in Prevalence	90	Norway	2	Female	149	15 to 24	1990-2019	-0.646785	-0.504751
969	Percent Change in Prevalence	71	Australia	2	Female	149	15 to 24	1990-2019	-0.599575	-0.430627
1230	Percent Change in Prevalence	216	Senegal	1	Male	149	15 to 24	1990-2019	-0.584283	-0.445845
991	Percent Change in Prevalence	83	Iceland	2	Female	149	15 to 24	1990-2019	-0.578069	-0.361854
1027	Percent Change in Prevalence	103	Latin America and Caribbean	2	Female	149	15 to 24	1990-2019	-0.569315	-0.482277
1226	Percent Change in Prevalence	214	Nigeria	1	Male	149	15 to 24	1990-2019	-0.567512	-0.398855
1064	Percent Change in Prevalence	125	Colombia	1	Male	149	15 to 24	1990-2019	-0.562606	-0.439109
1004	Percent Change in Prevalence	90	Norway	1	Male	149	15 to 24	1990-2019	-0.562134	-0.460321

	measure_name	location_id	location_name	sex_id	sex_name	age_group_id	age_group_name	year_id	wartosc_wskaznika	upp
425	Number of Smokers	1	Global	2	Female	149	15 to 24	2019	2.956645e+07	3.158243e+0
535	Number of Smokers	64	High-income	2	Female	149	15 to 24	2019	1.073082e+07	1.151689e+0
427	Number of Smokers	4	Southeast Asia, East Asia, and Oceania	2	Female	149	15 to 24	2019	3.597933e+06	4.678339e+0
603	Number of Smokers	103	Latin America and Caribbean	2	Female	149	15 to 24	2019	3.460183e+06	3.989620e+0
475	Number of Smokers	31	Central Europe, Eastern Europe, and Central Asia	2	Female	149	15 to 24	2019	3.388352e+06	3.703949e+0
703	Number of Smokers	158	South Asia	2	Female	149	15 to 24	2019	3.207666e+06	4.660905e+0
663	Number of Smokers	137	North Africa and Middle East	2	Female	149	15 to 24	2019	2.833469e+06	3.214529e+0
601	Number of Smokers	102	United States of America	2	Female	149	15 to 24	2019	2.803315e+06	3.466714e+0
711	Number of Smokers	163	India	2	Female	149	15 to 24	2019	2.516701e+06	3.967087e+0
717	Number of Smokers	166	Sub-Saharan Africa	2	Female	149	15 to 24	2019	2.348021e+06	2.676453e+0

location_name	sex_name	location_id	sex_id	age_group_id	wartosc_wskaznika	upper	lower
Afghanistan	**Female**	160.0	2.0	149.0	33057.933543	55651.202465	17680.436675
	Male	160.0	1.0	149.0	209298.444190	252585.438565	168869.405511
Albania	**Female**	43.0	2.0	149.0	8134.298835	11934.322209	5193.476422
	Male	43.0	1.0	149.0	31464.032152	34176.707054	28872.978583
Algeria	**Female**	139.0	2.0	149.0	16881.705940	28626.677430	9036.544290
...	**...**	...	...	...	...	...	...
Yemen	**Male**	157.0	1.0	149.0	190855.689376	229613.314591	156926.292400
Zambia	**Female**	191.0	2.0	149.0	46666.471372	70288.671872	29664.912560
	Male	191.0	1.0	149.0	100651.903955	117850.820974	85612.141930
Zimbabwe	**Female**	198.0	2.0	149.0	15966.118045	26591.376922	8609.222487
	Male	198.0	1.0	149.0	84868.371421	101445.018186	70898.890633

424 rows × 6 columns

location_name	wartosc_wskaznika	upper	lower
Afghanistan	121178.188867	4.514392	6
Albania	19799.165494	1.913974	6
Algeria	148576.461649	0.537529	6
American Samoa	548.214303	0.602564	6
Andorra	405.820017	0.386797	6
...	...	...	...
Venezuela (Bolivarian Republic of)	90975.309544	0.213780	6
Viet Nam	333682.697350	0.995869	6
Yemen	121210.525350	0.979173	6
Zambia	73659.187664	2.136812	6
Zimbabwe	50417.244733	2.923965	6

212 rows × 3 columns

```
['location_name', 'sex_name']
```

location_name	sex_name	location_id	sex_id	age_group_id	wartosc_wskaznika	upper	lower
Afghanistan	**Female**	160.0	2.0	149.0	33057.933543	55651.202465	17680.436675
	Male	160.0	1.0	149.0	209298.444190	252585.438565	168869.405511
Albania	**Female**	43.0	2.0	149.0	8134.298835	11934.322209	5193.476422
	Male	43.0	1.0	149.0	31464.032152	34176.707054	28872.978583
Algeria	**Female**	139.0	2.0	149.0	16881.705940	28626.677430	9036.544290
...	**...**	...	...	...	...	...	...
Yemen	**Male**	157.0	1.0	149.0	190855.689376	229613.314591	156926.292400
Zambia	**Female**	191.0	2.0	149.0	46666.471372	70288.671872	29664.912560
	Male	191.0	1.0	149.0	100651.903955	117850.820974	85612.141930
Zimbabwe	**Female**	198.0	2.0	149.0	15966.118045	26591.376922	8609.222487
	Male	198.0	1.0	149.0	84868.371421	101445.018186	70898.890633

424 rows × 6 columns

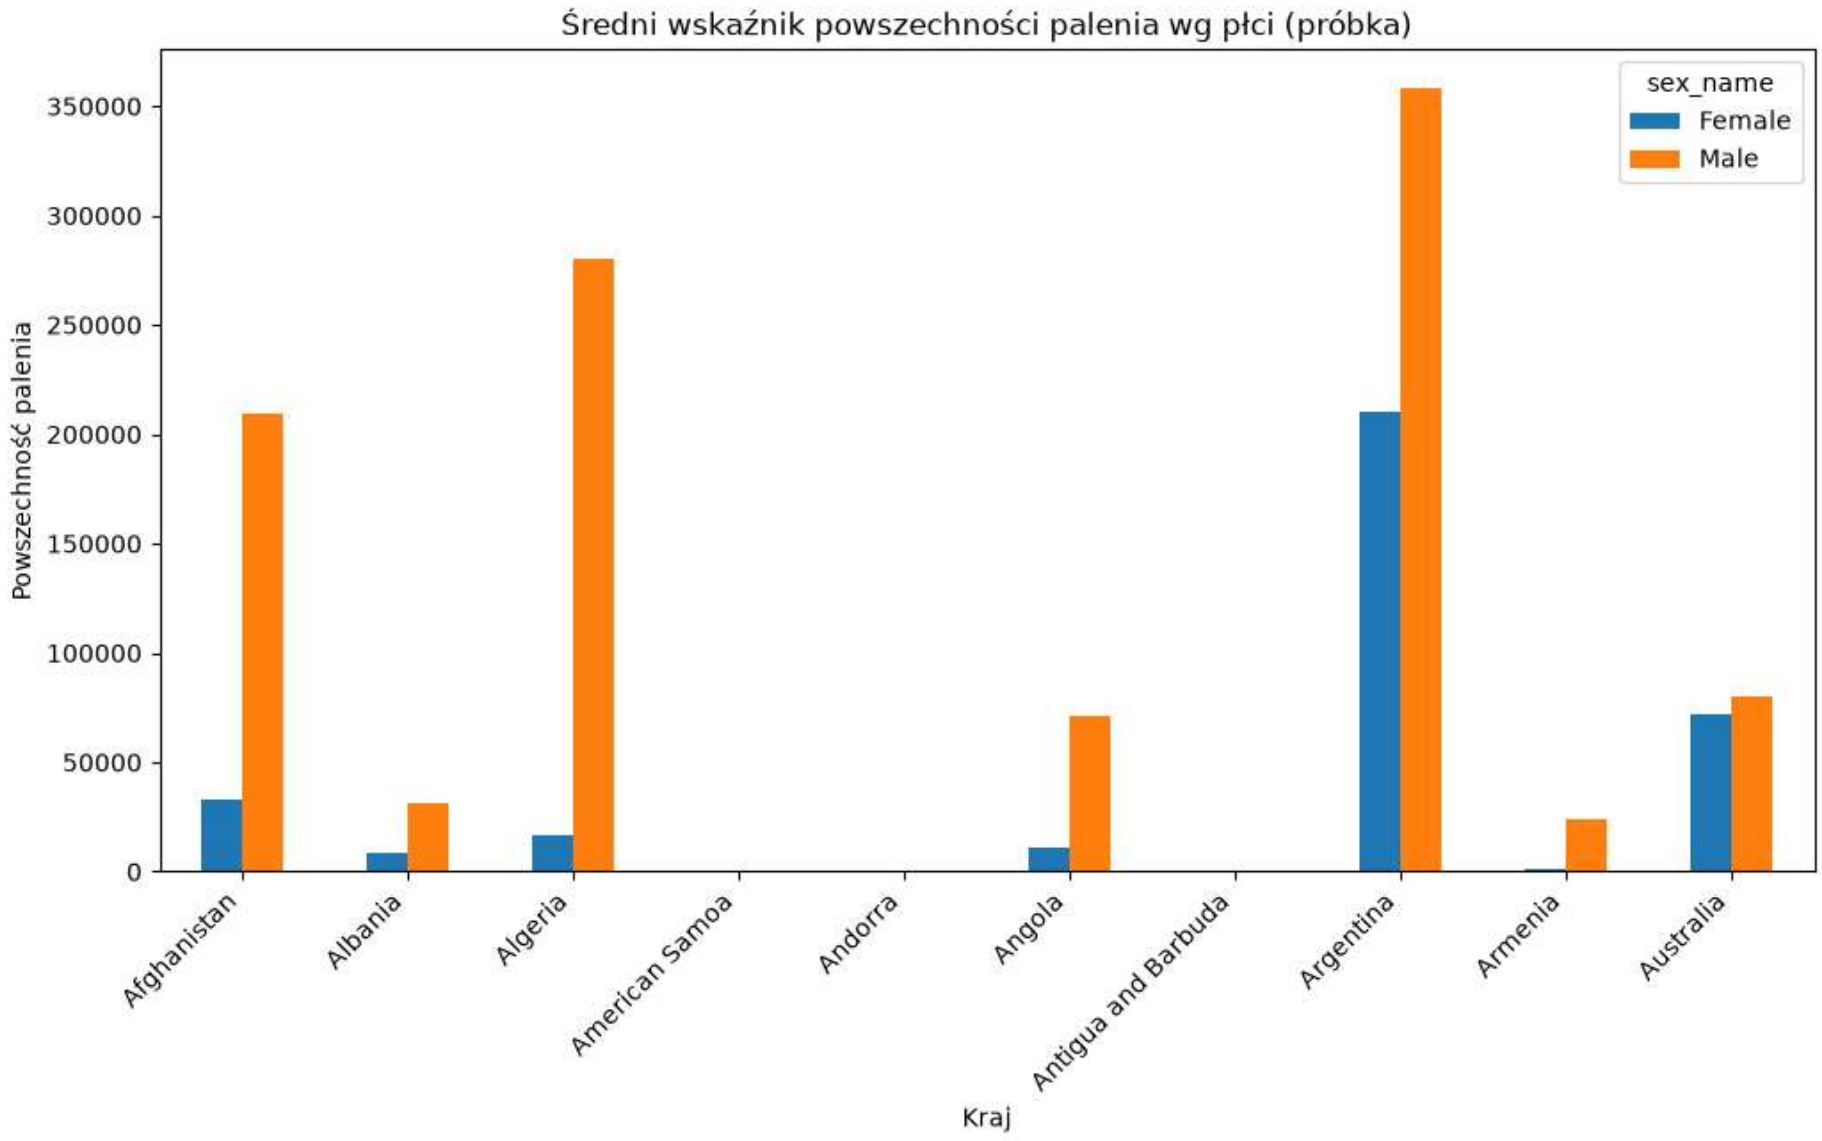
sex_name	Female	Male
location_name		
Afghanistan	33057.933543	209298.444190
Albania	8134.298835	31464.032152
Algeria	16881.705940	280271.217357
American Samoa	387.283822	709.144784
Andorra	375.271306	436.368728
...	...	...
Venezuela (Bolivarian Republic of)	52998.768611	128951.850477
Viet Nam	25302.952219	642062.442481
Yemen	51565.361325	190855.689376
Zambia	46666.471372	100651.903955
Zimbabwe	15966.118045	84868.371421

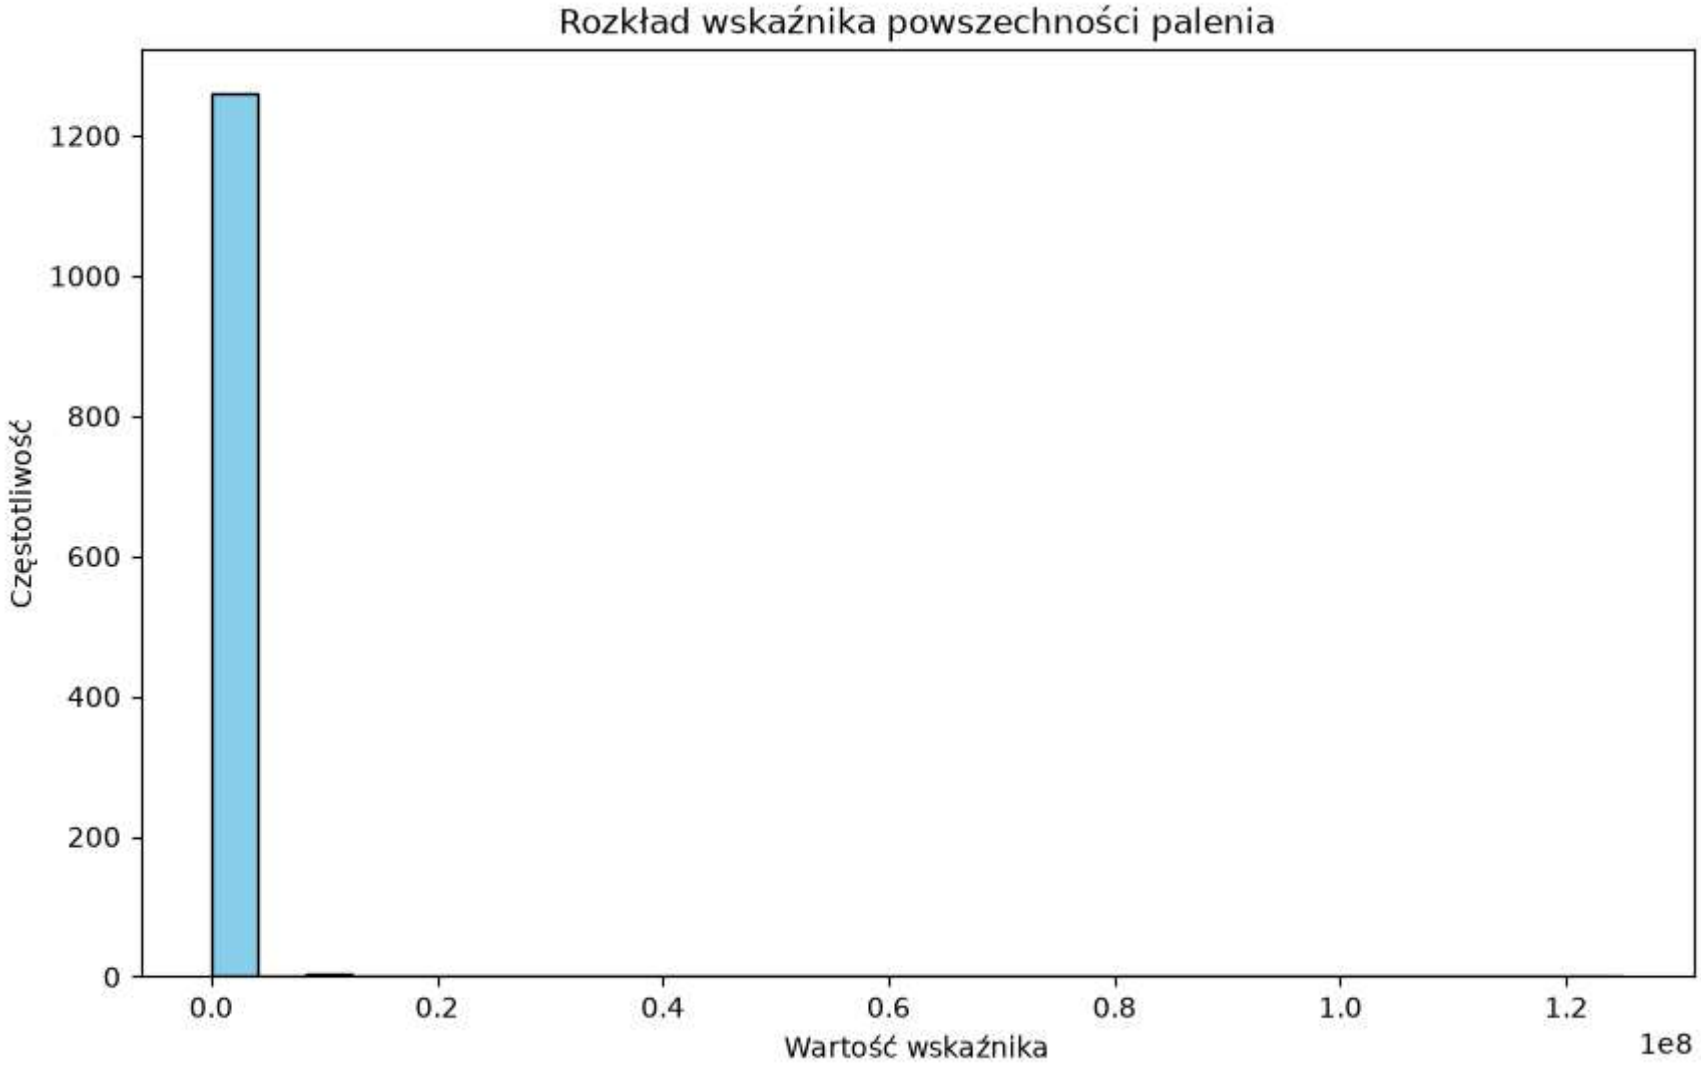
212 rows × 2 columns

```
Indeksy tabeli: Index(['Afghanistan', 'Albania', 'Algeria', 'American Samoa', 'Andorra',
       'Angola', 'Antigua and Barbuda', 'Argentina', 'Armenia', 'Australia',
       ...
       'United States Virgin Islands', 'United States of America', 'Uruguay',
       'Uzbekistan', 'Vanuatu', 'Venezuela (Bolivarian Republic of)',
       'Viet Nam', 'Yemen', 'Zambia', 'Zimbabwe'],
      dtype='str', name='location_name', length=212)
Kolumny tabeli: Index(['Female', 'Male'], dtype='str', name='sex_name')
```

	sex_name	Female	Male
location_name	age_group_name		
Afghanistan	**15 to 24**	33057.933543	209298.444190
Albania	**15 to 24**	8134.298835	31464.032152
Algeria	**15 to 24**	16881.705940	280271.217357
American Samoa	**15 to 24**	387.283822	709.144784
Andorra	**15 to 24**	375.271306	436.368728
...	**...**	...	...
Venezuela (Bolivarian Republic of)	**15 to 24**	52998.768611	128951.850477
Viet Nam	**15 to 24**	25302.952219	642062.442481
Yemen	**15 to 24**	51565.361325	190855.689376
Zambia	**15 to 24**	46666.471372	100651.903955
Zimbabwe	**15 to 24**	15966.118045	84868.371421

212 rows × 2 columns


Średni wskaźnik powszechności palenia wg płci (próbka)
sex_name
Female
Male
Powszechność palenia
350000
300000
250000
200000
150000
100000
50000
0
Afghanistan
Albania
Algeria
American Samoa
Andorra
Angola
Antigua and Barbuda
Argentina
Armenia
Australia
Kraj




```
Przykład pracy z argumentem chunksize:
Rozmiar przetworzonego fragmentu (chunk): (500, 11)
Rozmiar przetworzonego fragmentu (chunk): (500, 11)
Rozmiar przetworzonego fragmentu (chunk): (272, 11)
```